



MÉTODOS DE MACHINE LEARNING PARA RECONCILIAÇÃO ÓTIMA DE SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS DE INSTITUIÇÕES FINANCEIRAS

DEFESA DE DISSERTAÇÃO DE MESTRADO

Alberson Miranda, PPGEco/UFES

Fevereiro de 2024



SUMÁRIO

1 CONTEXTUALIZAÇÃO DA PESQUISA

► CONTEXTUALIZAÇÃO DA PESQUISA

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► OBJETIVOS

► METODOLOGIA

► RESULTADOS

► CONCLUSÃO



ANÁLISE DE SÉRIES TEMPORAIS EM ECONOMIA BANCÁRIA

1 CONTEXTUALIZAÇÃO DA PESQUISA

- Problemas populares na literatura: risco de crédito, detecção de anomalias (fraude), preços de ativos, alocação ótima de numerários (SEZER; GUDELEK; OZBAYOGLU, 2019)
- Pouco sobre projeção de saldos e rendas (*guidance, budgeting*)
- Previsões equivocadas = percepção de incompetência, redução de reputação e receitas (BECCALLI et al., 2015)
- Orçamentação em empresas de muitas filiais: alta dimensionalidade e dúvidas



ANÁLISE DE SÉRIES TEMPORAIS EM ECONOMIA BANCÁRIA

1 CONTEXTUALIZAÇÃO DA PESQUISA

- Banestes: 134 agências, 78 municípios do ES, 13 microrregiões, 4 mesorregiões
- Qual a melhor forma de realizar projeções?
 - Individualmente por agência?
 - Apenas o total e distribuir proporcionalmente?
 - As informações por mesorregião ou microrregião são importantes?
 - Como usar toda a informação?



SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS


1 CONTEXTUALIZAÇÃO DA PESQUISA

Séries temporais hierárquicas são aquelas que podem ser agregadas ou desagregadas naturalmente em uma estrutura aninhada (HYNDMAN; ATHANASOPOULOS, 2021)



SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

1 CONTEXTUALIZAÇÃO DA PESQUISA





SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS


1 CONTEXTUALIZAÇÃO DA PESQUISA

Séries temporais agrupadas são aquelas que não impõem uma única estrutura hierárquica



SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

1 CONTEXTUALIZAÇÃO DA PESQUISA





COERÊNCIA E RECONCILIAÇÃO

1 CONTEXTUALIZAÇÃO DA PESQUISA

- Coerência: cada nó da hierarquia deve totalizar os nós filhos
- Não há razão para que as previsões individuais (e.g., Arima, ETS) sejam coerentes

RECONCILIAÇÃO ÓTIMA

Reescrever as previsões de forma que elas sejam coerentes, utilizando toda a informação disponível na estrutura hierárquica, ao mesmo tempo em que minimiza a variância do erro de previsão



BOTTOM-UP

1 CONTEXTUALIZAÇÃO DA PESQUISA

- informações apenas dos níveis mais desagregados
- soma-se para obter os níveis agregados



TOP-DOWN

1 CONTEXTUALIZAÇÃO DA PESQUISA

- apenas informações do nível mais agregado
- há dezenas de métodos para distribuir proporcionalmente as previsões agregadas (GROSS; SOHL, 1990)
- não podem ser utilizadas no contexto de séries temporais agrupadas¹.

¹Desambiguar uma estrutura agrupada resulta em uma estrutura hierárquica, mas há necessariamente perda de informação (e.g., fixar os verbetes abaixo das agências, causaria a perda da informação do agregado dos verbetes).



SUMÁRIO

2 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► CONTEXTUALIZAÇÃO DA PESQUISA

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► OBJETIVOS

► METODOLOGIA

► RESULTADOS

► CONCLUSÃO



NOTAÇÃO MATRICIAL

2 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

$$\tilde{y}_t = SG\hat{y}_t \quad (1)$$

Em que

- \tilde{y}_t é o vetor de previsões reconciliadas
- S é a matriz de soma
- G é a matriz de reconciliação
- \hat{y}_t é o vetor de previsões base



MATRIZ DE RECONCILIAÇÃO

2 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

PROBLEMA DE REGRESSÃO

- Minimização do traço da matriz de covariância dos erros das previsões reconciliadas ($\text{Min}T^a$)

$$\min_{\tilde{e}} y_{T+h} - \tilde{y}_{T+h} \quad (2)$$

- Mínimos Quadrados Generalizados (MQG)

$$G = (S'W_h^\dagger S)^{-1} S'W_h^\dagger \quad (3)$$

Substituindo G na Equação 1, temos:

$$\tilde{y} = S(S'W_h^\dagger S)^{-1} S'W_h^\dagger \hat{y}_h \quad (4)$$

^a(WICKRAMASURIYA; ATHANASOPOULOS; HYNDMAN, 2019).



RECONCILIAÇÃO POR MACHINE LEARNING

2 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

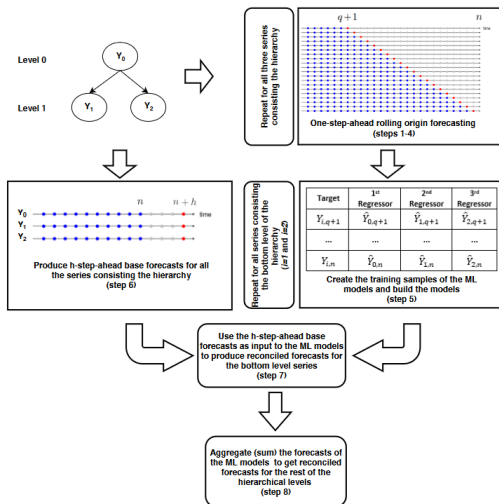


Figure 1: Abordagem de reconciliação ótima por ML. Fonte: Spiliotis et al. (2021)



SUMÁRIO

3 OBJETIVOS

► CONTEXTUALIZAÇÃO DA PESQUISA

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► **OBJETIVOS**

► METODOLOGIA

► RESULTADOS

► CONCLUSÃO



OBJETIVO GERAL

3 OBJETIVOS

Estudar o problema da reconciliação ótima de previsões pontuais a partir de métodos de *machine learning* em séries temporais hierárquicas e agrupadas do Banco do Estado do Espírito Santo



OBJETIVOS ESPECÍFICOS

3 OBJETIVOS

1. Estender a abordagem de Spiliotis et al. (2021) para a reconciliação ótima de séries temporais hierárquicas *e agrupadas*;
2. Avaliar a efetividade de mais 4 implementações de métodos de ML (*lasso*, *ridge*, *elastic net*, SVM e *lightGBM*), além dos 2 propostos no trabalho original (*XGBoost* e *random forest*);
3. Propor duas variações metodológicas para obtenção da amostra de treino dos modelos de ML;
4. Obter ganhos de performance no contexto de séries temporais financeiras.



SUMÁRIO

4 METODOLOGIA

- ▶ CONTEXTUALIZAÇÃO DA PESQUISA
- ▶ RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS
- ▶ OBJETIVOS
- ▶ **METODOLOGIA**
- ▶ RESULTADOS
- ▶ CONCLUSÃO



DADOS E VARIÁVEIS

4 METODOLOGIA

- Estatística Bancária Mensal e por Município (Bacen)
- Municípios (IBGE)
- Saldos de crédito dos verbetes empréstimos e financiamentos
- CNPJ Banestes mas expansível para todo SFN
- 01/2003 - 12/2022
- 37.920 observações (114.480 com nós de agregação)



DADOS E VARIÁVEIS

4 METODOLOGIA

- Estrutura hierárquica
 - total
 - 4 mesorregiões
 - 13 microrregiões
 - 79 agências
- Estrutura agrupada
 - 2 modalidades de crédito



PREVISÕES BASE

4 METODOLOGIA

- Previsões para fora da amostra a serem reconciliadas
- ETS (podem ser obtidas por qualquer método, incluindo ML)
- Treino: 01/2003 - 12/2021
- Horizonte de previsão (h): 01/2022 - 12/2022, fora da amostra



DESIGN DO EXPERIMENTO

4 METODOLOGIA

Dado um conjunto de previsões base, o quanto mais precisas elas se tornam ao se aplicar um determinado método de reconciliação?



DESIGN DO EXPERIMENTO

4 METODOLOGIA

Metodologia de Spiliotis et al. (2021):

1. Previsões para dentro da amostra (ETS)
2. Treino dos modelos de ML para cada y_m
3. Reconciliação ótima das previsões base (fora da amostra)
4. Agregação das previsões reconciliadas para obtenção dos demais níveis hierárquicos



DESIGN DO EXPERIMENTO

4 METODOLOGIA

METODOLOGIA ML VERSUS MINT

As principais diferenças entre os ambas metodologias são:

- A utilização de algoritmos de ML ao invés de MQG (permitindo combinações não lineares)
- A não atribuição de peso de forma obrigatória para todos os nós da hierarquia
- O ajuste de um modelo individual para cada série do nível mais desagregado, permitindo maior especialização e sendo capaz de se adaptar melhor aos diferentes padrões de cada série (SPILIOTIS et al., 2021).



DESIGN DO EXPERIMENTO

4 METODOLOGIA

- Métodos de reconciliação:
 - Analíticos: *Bottom-up* e *MinT Shrink*
 - Regressão regularizada: *Elastic Net* (lasso, ridge e CV)
 - Árvores: *Random forest*, *XGBoost* e *LightGBM*
 - *Support Vector Machines* (SVM)
- Estratégias para obtenção das previsões *in-sample*:
 - *Rolling forecast*
 - *Reduced fitted base forecasts*
 - *Fitted base forecasts*



ESTRATÉGIA ROLLING FORECAST

4 METODOLOGIA




Figure 2: Estratégia Rolling Forecast



ESTRATÉGIA REDUCED FITTED BASE

4 METODOLOGIA

- Desvantagem do *Rolling Forecast*: a cada h , um novo modelo é ajustado, totalizando $m \times p = 17064$ modelos.
- *Reduced fitted base*: ajusta-se apenas m modelos, com dados até Q e então reestima-se esses modelos passando-se o restante do conjunto de treinamento ($Q + p$), conservando os hiperparâmetros originais. Os valores ajustados dos modelos reestimados são utilizados para treinar os modelos de ML.



ESTRATÉGIA FITTED BASE

4 METODOLOGIA

- Pode ser um problema obter previsões para dentro da amostra para séries de poucas observações ou incompletas
- *Fitted base*: utiliza-se os valores ajustados dos modelos de previsão base obtidos ao longo de todo o período $q = 1, 2, 3, \dots, Q + p$ (todo conjunto de treinamento)



OTIMIZAÇÃO DE HIPERPARÂMETROS

4 METODOLOGIA

- Bischl et al. (2021)
- m modelos calibrados individualmente
- *grid* para *elastic net* e bayesiana os demais métodos
- *Resampling*: CV-10, RMSE



SUMÁRIO

5 RESULTADOS

- ▶ CONTEXTUALIZAÇÃO DA PESQUISA
- ▶ RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS
- ▶ OBJETIVOS
- ▶ METODOLOGIA
- ▶ **RESULTADOS**
- ▶ CONCLUSÃO



ESTBAN - ANALÍTICOS

5 RESULTADOS

.model	agregado	mesorregiao	microrregiao	municipio	agencia	verbete	bottom	hierarquia
RMSSE								
base	0.197	0.690	0.846	0.671	0.717	0.183	0.656	0.657
bu	0.196	0.561	0.706	0.710	0.739	0.185	0.656	0.663
mint	0.172	0.619	0.722	0.689	0.712	0.140	0.634	0.641
MASE								
base	0.278	0.818	0.998	0.790	0.886	0.250	0.883	0.847
bu	0.240	0.572	0.771	0.820	0.895	0.221	0.883	0.844
mint	0.224	0.692	0.865	0.830	0.891	0.164	0.864	0.837



ESTBAN - ML - ROLLING FORECAST

5 RESULTADOS

modelo	agregado	mesorregiao	microrregiao	municipio	agencia	verbete	bottom	hierarquia
RMSSE								
elastic net	0.280	0.763	1.178	1.211	1.251	0.770	1.062	1.094
lasso	0.196	0.726	1.054	0.995	1.043	0.501	0.839	0.882
lightgbm	1.407	1.628	1.530	1.294	1.322	0.883	0.972	1.095
random forest	1.227	1.397	1.303	1.118	1.171	0.725	0.858	0.949
ridge	0.416	0.776	1.131	1.511	1.535	0.919	1.357	1.368
svm	0.262	0.745	0.858	0.853	0.911	0.234	0.847	0.838
xgb	1.186	1.405	1.296	1.096	1.139	0.700	0.830	0.924
MASE								
elastic net	0.234	0.726	1.406	1.491	1.582	0.949	1.439	1.428
lasso	<u>0.166</u>	0.714	1.250	1.193	1.298	0.641	1.142	1.147
lightgbm	1.890	1.896	1.874	1.600	1.654	1.234	1.390	1.478
random forest	1.615	1.560	1.501	1.332	1.423	0.996	1.097	1.177
ridge	0.402	0.757	1.315	1.800	1.881	1.090	1.790	1.738
svm	0.306	0.684	0.862	0.991	1.108	0.290	1.251	1.143
xgb	1.542	1.564	1.479	1.297	1.373	0.948	1.022	1.115



ESTBAN - ML - FITTED BASE

5 RESULTADOS

modelo	agregado	mesorregiao	microrregiao	municipio	agencia	verbete	bottom	hierarquia
RMSSE								
elastic net	0.777	0.986	1.086	1.038	1.149	0.579	0.924	0.961
lasso	0.661	0.955	1.074	0.909	1.008	0.530	0.826	0.862
lightgbm	1.495	1.649	1.557	1.300	1.342	0.923	0.999	1.116
random forest	1.204	1.397	1.294	1.098	1.150	0.694	0.839	0.930
ridge	1.001	1.146	1.247	1.208	1.327	0.689	1.125	1.147
svm	0.395	0.929	0.928	0.934	0.961	0.319	0.905	0.898
xgb	1.196	1.373	1.282	1.084	1.133	0.699	0.824	0.916
MASE								
elastic net	1.049	1.143	1.317	1.268	1.451	0.795	1.290	1.284
lasso	0.894	1.087	1.319	1.114	1.276	0.728	1.167	1.162
lightgbm	2.027	1.931	1.906	1.610	1.683	1.302	1.433	1.512
random forest	1.576	1.557	1.488	1.311	1.397	0.947	1.043	1.132
ridge	1.338	1.350	1.549	1.501	1.696	0.935	1.584	1.551
svm	0.445	0.947	1.080	1.163	1.226	0.341	1.282	1.217
xgb	1.545	1.509	1.476	1.293	1.375	0.942	1.017	1.109



ESTBAN - ML - REDUCED FITTED BASE

5 RESULTADOS

modelo	agregado	mesorregiao	microrregiao	municipio	agencia	verbeta	bottom	hierarquia
RMSSE								
elastic net	0.090	0.582	0.730	0.819	0.838	0.164	0.730	0.736
lasso	<u>0.132</u>	0.523	0.766	0.757	0.774	0.187	0.681	0.693
lightgbm	1.406	1.588	1.520	1.281	1.323	0.889	0.971	1.091
random forest	1.248	1.409	1.319	1.119	1.167	0.692	0.857	0.949
ridge	<u>0.141</u>	0.635	0.784	0.902	0.922	0.207	0.841	0.829
svm	0.187	0.743	0.767	0.792	0.834	0.295	0.807	0.792
xgb	1.218	1.347	1.253	1.084	1.140	0.708	0.844	0.927
MASE								
elastic net	0.086	0.584	0.834	0.973	1.008	0.208	0.944	0.922
lasso	<u>0.138</u>	0.520	0.883	0.907	0.933	0.216	0.891	0.878
lightgbm	1.879	1.831	1.832	1.580	1.652	1.236	1.388	1.470
random forest	1.636	1.576	1.526	1.333	1.418	0.947	1.065	1.155
ridge	<u>0.159</u>	0.630	0.894	1.047	1.087	0.231	1.073	1.021
svm	0.225	0.764	0.850	0.949	1.022	0.395	1.176	1.083
xgb	1.593	1.491	1.427	1.293	1.380	0.965	1.064	1.137



ESTBAN - ML - TEMPO DE PROCESSAMENTO

5 RESULTADOS

	xgb	random forest	elastic net	lasso	ridge	svm	lightgbm
reduced fitted base	19.235	5.483	1.428	0.879	0.993	1.279	3.290
fitted base	21.758	5.521	1.363	0.829	0.924	1.273	3.341
rolling forecast	20.908	5.429	1.345	0.838	0.929	1.285	3.377



TOURISM - ANALÍTICOS

5 RESULTADOS

.model	agregado	state	region	purpose	bottom	hierarquia
RMSSE						
base	1.446	1.260	1.068	1.265	0.925	0.976
bu	2.580	1.634	1.113	2.004	0.925	1.011
mint	1.813	1.296	0.978	1.420	0.876	0.923
MASE						
base	1.533	1.399	1.132	1.330	0.979	1.036
bu	3.164	1.877	1.176	2.323	0.979	1.078
mint	2.086	1.449	1.021	1.512	0.937	0.984



TOURISM - ML - ROLLING FORECAST

5 RESULTADOS

modelo	agregado	State	Region	Purpose	bottom	hierarquia
RMSSE						
elastic net	1.990	1.386	1.086	1.541	0.988	1.041
lasso	1.929	1.373	1.100	1.523	1.026	1.069
lightgbm	4.330	2.762	1.651	3.456	1.141	1.354
random forest	2.135	1.365	1.033	1.709	0.908	0.966
ridge	<u>1.256</u>	<u>1.185</u>	1.013	<u>1.202</u>	0.919	0.959
svm	0.940	1.010	1.076	1.011	1.100	1.097
xgb	2.340	1.451	1.114	1.892	0.964	1.031
MASE						
elastic net	2.360	1.572	1.145	1.653	1.058	1.115
lasso	2.264	1.557	1.168	1.593	1.110	1.155
lightgbm	5.505	3.214	1.763	4.060	1.200	1.448
random forest	2.579	1.528	1.073	1.816	0.961	1.020
ridge	<u>1.343</u>	<u>1.309</u>	1.058	<u>1.192</u>	0.981	1.020
svm	1.070	1.096	1.140	1.033	1.178	1.174
xgb	2.888	1.650	1.162	2.118	1.013	1.087



TOURISM - ML - FITTED BASE

5 RESULTADOS

modelo	agregado	State	Region	Purpose	bottom	hierarquia
RMSSE						
elastic net	2.17	1.40	1.10	1.77	0.97	1.03
lasso	1.90	1.45	1.09	1.61	0.97	1.03
lightgbm	4.33	2.76	1.65	3.46	1.14	1.35
random forest	2.12	1.36	1.03	1.72	0.91	0.96
ridge	1.57	<u>1.16</u>	0.97	1.29	0.90	0.93
svm	1.50	<u>1.19</u>	1.05	1.38	1.04	1.05
xgb	2.27	1.42	1.10	1.83	0.96	1.02
MASE						
elastic net	2.59	1.57	1.16	1.95	1.04	1.10
lasso	2.21	1.67	1.16	1.73	1.04	1.11
lightgbm	5.50	3.21	1.76	4.06	1.20	1.45
random forest	2.54	1.54	1.07	1.84	0.97	1.02
ridge	1.77	<u>1.29</u>	1.01	<u>1.31</u>	0.96	0.99
svm	1.75	<u>1.30</u>	1.09	1.36	1.10	1.11
xgb	2.79	1.62	1.15	2.04	1.01	1.08



TOURISM - ML - REDUCED FITTED BASE

5 RESULTADOS

modelo	agregado	State	Region	Purpose	bottom	hierarquia
RMSSE						
lightgbm	4.33	2.76	1.65	3.46	1.14	1.35
random forest	2.58	1.55	1.11	2.01	0.92	1.01
xgb	3.14	1.93	1.28	2.44	1.02	1.14
MASE						
lightgbm	5.50	3.21	1.76	4.06	1.20	1.45
random forest	3.18	1.76	1.17	2.24	0.98	1.07
xgb	3.93	2.27	1.38	2.86	1.07	1.21



TOURISM - ML - TEMPO DE PROCESSAMENTO

5 RESULTADOS

	xgb	random forest	elastic net	lasso	ridge	svm	lightgbm
fitted base	15.767	3.687	1.540	1.282	1.371	1.977	3.535
rolling forecast	12.087	2.987	0.957	0.796	1.073	2.035	3.596
reduced fitted base	24.627	15.386	6.006	4.968	5.323	10.474	19.362



RESULTADOS

5 RESULTADOS

- Os métodos baseados em árvore, além de requererem maior tempo de processamento devido a sua complexidade no espaço de hiperparâmetros, também tenderam a perder qualidade de performance nos níveis superiores da hierarquia
- Os métodos de regressão regularizada e o SVM se mostraram mais robustos à agregação
- Nenhum combinação de método/estratégia é consistentemente melhor ao longo de todos os níveis de agregação



RESULTADOS

5 RESULTADOS

- Para o nível agregado, o *elastic net* na estratégia *reduced fitted base* foi 91% melhor que o MinT
- Para as mesorregiões, o Lasso superou o BU em 7%
- Nos demais níveis hierárquicos, os métodos analíticos superaram os de ML (*idem* TOURISM)



SUMÁRIO

6 CONCLUSÃO

- ▶ CONTEXTUALIZAÇÃO DA PESQUISA
- ▶ RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS
- ▶ OBJETIVOS
- ▶ METODOLOGIA
- ▶ RESULTADOS
- ▶ CONCLUSÃO



OUTLINE

6 CONCLUSÃO

- Os métodos de ML podem trazer ganhos de performance substanciais em relação aos analíticos
- A metodologia de reconciliação ótima desenvolvida neste trabalho pode ser estendida para todo o SFN e para outros problemas de previsão de séries temporais



OUTLINE

6 CONCLUSÃO

- A escolha do método dependerá do objetivo do pesquisador:
 - Para elaboração de metas individuais, os métodos analíticos se mostraram preferíveis
 - Para previsão dos níveis mais agregados, os métodos lineares de ML obtiveram melhor performance
 - Os métodos baseados em árvore de decisão não foram capazes de superar os analíticos em nenhum nível de agregação



OUTLINE

6 CONCLUSÃO

- Não houve uma combinação de método e estratégia que obtivesse melhor performance de maneira consistente ao longo de todos os níveis hierárquicos
- A performance da reconciliação ótima é sensível à estratégia de geração de previsões para dentro da amostra



REFERÊNCIAS

6 CONCLUSÃO



BECCALLI, E. et al. Earnings management, forecast guidance and the banking crisis. **The European Journal of Finance**, v. 21, n. 3, p. 242–268, fev. 2015. ISSN 1351-847X. DOI: 10.1080/1351847X.2013.809548. Disponível em: <<https://doi.org/10.1080/1351847X.2013.809548>>. Acesso em: 7 mai. 2023. Citado na p. 3.



BISCHL, B. et al. **Hyperparameter Optimization: Foundations, Algorithms, Best Practices and Open Challenges**. [S.l.]: arXiv, nov. 2021. arXiv:2107.05847 [cs, stat]. DOI: 10.48550/arXiv.2107.05847. Disponível em: <<http://arxiv.org/abs/2107.05847>>. Acesso em: 4 set. 2023. Citado na p. 30.



GROSS, C. W.; SOHL, J. E. Disaggregation methods to expedite product line forecasting. en. **Journal of Forecasting**, v. 9, n. 3, p. 233–254, 1990. ISSN 1099-131X. DOI: 10.1002/for.3980090304. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/for.3980090304>>. Acesso em: 18 jun. 2023. Citado na p. 11.



REFERÊNCIAS

6 CONCLUSÃO



HYNDMAN, R.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3. ed. Melbourne, Austrália: OTexts, 2021. Disponível em: <<https://otexts.com/fpp3/>>. Citado na p. 5.



SEZER, O. B.; GUDELEK, M. U.; OZBAYOGLU, A. M. **Financial Time Series Forecasting with Deep Learning : A Systematic Literature Review: 2005-2019**. Turquia: arXiv, nov. 2019. arXiv:1911.13288 [cs, q-fin, stat]. Disponível em: <<http://arxiv.org/abs/1911.13288>>. Acesso em: 7 mar. 2023. Citado na p. 3.



SPILIOTIS, E. et al. Hierarchical forecast reconciliation with machine learning. en. **Applied Soft Computing**, v. 112, p. 107756, nov. 2021. ISSN 1568-4946. DOI: 10.1016/j.asoc.2021.107756. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1568494621006773>>. Acesso em: 11 jan. 2023. Citado nas pp. 15, 18, 24, 25.



REFERÊNCIAS

6 CONCLUSÃO



WICKRAMASURIYA, S. L.; ATHANASOPOULOS, G.; HYNDMAN, R. J. Optimal Forecast Reconciliation for Hierarchical and Grouped Time Series Through Trace Minimization. en. **Journal of the American Statistical Association**, v. 114, n. 526, p. 804–819, abr. 2019. ISSN 0162-1459, 1537-274X. DOI: 10.1080 / 01621459.2018.1448825. Disponível em: <<https://www.tandfonline.com/doi/full/10.1080/01621459.2018.1448825>>. Acesso em: 18 jun. 2023. Citado na p. 14.



MÉTODOS DE MACHINE LEARNING PARA RECONCILIAÇÃO ÓTIMA DE SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS DE INSTITUIÇÕES FINANCEIRAS

DEFESA DE DISSERTAÇÃO DE MESTRADO

Alberson Miranda, PPGEco/UFES

Fevereiro de 2024