



# **MÉTODOS DE MACHINE LEARNING PARA RECONCILIAÇÃO ÓTIMA DE SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS DE INSTITUIÇÕES FINANCEIRAS**

DEFESA DE DISSERTAÇÃO DE MESTRADO

Alberson Miranda, PPGeco/UFES

2024



# SUMÁRIO

## 1 CONTEXTUALIZAÇÃO DA PESQUISA

### ▶ CONTEXTUALIZAÇÃO DA PESQUISA

### ▶ OBJETIVOS

### ▶ RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

### ▶ METODOLOGIA

### ▶ REFERÊNCIAS



# ANÁLISE DE SÉRIES TEMPORAIS EM ECONOMIA BANCÁRIA

## 1 CONTEXTUALIZAÇÃO DA PESQUISA

- Problemas populares na literatura: risco de crédito, detecção de anomalias (fraude), preços de ativos, alocação ótima de numerários (SEZER; GUDELEK; OZBAYOGLU, 2019)
- Pouco sobre projeção de saldos e rendas (*guidance, budgeting*)
- Previsões equivocadas = percepção de incompetência, redução de reputação e receitas (BECCALLI et al., 2015)
- Orçamentação em empresas de muitas filiais: alta dimensionalidade e dúvidas



# ANÁLISE DE SÉRIES TEMPORAIS EM ECONOMIA BANCÁRIA

## 1 CONTEXTUALIZAÇÃO DA PESQUISA

- Banestes: 134 agências, 78 municípios do ES, 13 microrregiões, 4 mesorregiões
- Qual a melhor forma de realizar projeções?
  - Individualmente por agência?
  - Apenas o total e distribuir proporcionalmente?
  - As informações por mesorregião ou microrregião são importantes?
  - Como usar toda a informação?



# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS


## 1 CONTEXTUALIZAÇÃO DA PESQUISA

Séries temporais hierárquicas são aquelas que podem ser agregadas ou desagregadas naturalmente em uma estrutura aninhada (HYNDMAN; ATHANASOPOULOS, 2021)



# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

## 1 CONTEXTUALIZAÇÃO DA PESQUISA





# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

## 1 CONTEXTUALIZAÇÃO DA PESQUISA

- Cada nível traz informação diferente
- É razoável supor que exista covariância entre as previsões dos diferentes níveis
- Toda informação da estrutura pode ser útil



# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

## 1 CONTEXTUALIZAÇÃO DA PESQUISA


Séries temporais agrupadas são aquelas que não impõem uma única estrutura hierárquica





# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS


## 1 CONTEXTUALIZAÇÃO DA PESQUISA





# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS


## 1 CONTEXTUALIZAÇÃO DA PESQUISA





# SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS

## 1 CONTEXTUALIZAÇÃO DA PESQUISA





# COERÊNCIA E RECONCILIAÇÃO

## 1 CONTEXTUALIZAÇÃO DA PESQUISA

- Coerência: cada nó da hierarquia deve totalizar os nós filhos
- Não há razão para que as previsões individuais (e.g., Arima, ETS) sejam coerentes

### RECONCILIAÇÃO ÓTIMA

Reescrever as previsões de forma que elas sejam coerentes, utilizando toda a informação disponível na estrutura hierárquica, ao mesmo tempo em que minimiza a variância do erro de previsão



# SUMÁRIO

## 2 OBJETIVOS

► CONTEXTUALIZAÇÃO DA PESQUISA

► OBJETIVOS

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► METODOLOGIA

► REFERÊNCIAS



# OBJETIVO GERAL

## 2 OBJETIVOS

Estudar o problema da reconciliação ótima de previsões pontuais a partir de métodos de *machine learning* em séries temporais hierárquicas e agrupadas do Banco do Estado do Espírito Santo



# OBJETIVOS ESPECÍFICOS

## 2 OBJETIVOS

1. Estender a abordagem de Spiliotis et al. (2021) para a reconciliação ótima de séries temporais hierárquicas *e agrupadas*;
2. Avaliar a efetividade de mais 4 implementações de métodos de ML (*lasso*, *ridge*, *elastic net*, SVM e *lightGBM*), além dos 2 propostos no trabalho original (*XGBoost* e *random forest*);
3. Propor duas variações metodológicas para obtenção da amostra de treino dos modelos de ML;
4. Obter ganhos de performance no contexto de séries temporais financeiras.



# SUMÁRIO

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► CONTEXTUALIZAÇÃO DA PESQUISA

► OBJETIVOS

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► METODOLOGIA

► REFERÊNCIAS





# BOTTOM-UP

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

- informações apenas dos níveis mais desagregados
- soma-se para obter os níveis agregados



# TOP-DOWN

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

- apenas informações do nível mais agregado
- há dezenas de métodos para distribuir proporcionalmente as previsões agregadas (GROSS; SOHL, 1990)
- não podem ser utilizadas no contexto de séries temporais agrupadas<sup>1</sup>.

---

<sup>1</sup>Desambiguar uma estrutura agrupada resulta em uma estrutura hierárquica, mas há necessariamente perda de informação (e.g., fixar os verbetes abaixo das agências, causaria a perda da informação do agregado dos verbetes).



# MIDDLE-OUT

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

- informações apenas de um nível intermediário
- soma-se para obter os níveis agregados e distribui-se proporcionalmente para os níveis mais desagregados



# NOTAÇÃO MATRICIAL

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

$$\tilde{y}_t = SG\hat{y}_t \quad (1)$$

Em que

- $\tilde{y}_t$  é o vetor de previsões reconciliadas
- $S$  é a matriz de soma
- $G$  é a matriz de reconciliação
- $\hat{y}_t$  é o vetor de previsões base



# MATRIZ DE SOMA

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

$S$  mapeia a estrutura hierárquica a partir da soma dos elementos mais desagregados

$$\begin{bmatrix} \tilde{y}_t \\ \tilde{y}_{A,t} \\ \tilde{y}_{B,t} \\ \tilde{y}_{AA,t} \\ \tilde{y}_{AB,t} \\ \tilde{y}_{AC,t} \\ \tilde{y}_{BA,t} \\ \tilde{y}_{BB,t} \end{bmatrix}_{8 \times 1} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}_{8 \times 5} \begin{bmatrix} \hat{y}_{AA,t} \\ \hat{y}_{AB,t} \\ \hat{y}_{AC,t} \\ \hat{y}_{BA,t} \\ \hat{y}_{BB,t} \end{bmatrix}_{5 \times 1} \quad (2)$$

*exemplo 1: matriz de soma*



# MATRIZ DE RECONCILIAÇÃO

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

$G$  mapeia o nível mais desagregado a partir das previsões de todos os níveis da hierarquia, garantindo a coerência

$$\begin{bmatrix} \tilde{y}_t \\ \tilde{y}_{A,t} \\ \tilde{y}_{B,t} \\ \tilde{y}_{AA,t} \\ \tilde{y}_{AB,t} \\ \tilde{y}_{AC,t} \\ \tilde{y}_{BA,t} \\ \tilde{y}_{BB,t} \end{bmatrix}_{8 \times 1} = S_{n \times m} \begin{bmatrix} p_1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_3 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_4 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ p_5 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}_{5 \times 8} \begin{bmatrix} \hat{y}_{T+h|T} \\ \hat{y}_{A,T+h|T} \\ \hat{y}_{B,T+h|T} \\ \hat{y}_{AA,T+h|T} \\ \hat{y}_{AB,T+h|T} \\ \hat{y}_{AC,T+h|T} \\ \hat{y}_{BA,T+h|T} \\ \hat{y}_{BB,T+h|T} \end{bmatrix}_{8 \times 1} \quad (3)$$

*exemplo 2: matriz de reconciliação top-down*



# MATRIZ DE RECONCILIAÇÃO

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

$$\begin{bmatrix} \tilde{y}_t \\ \tilde{y}_{A,t} \\ \tilde{y}_{B,t} \\ \tilde{y}_{AA,t} \\ \tilde{y}_{AB,t} \\ \tilde{y}_{AC,t} \\ \tilde{y}_{BA,t} \\ \tilde{y}_{BB,t} \end{bmatrix}_{8 \times 1} = \mathbf{S}_{8 \times 5} \begin{bmatrix} 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}_{5 \times 8} \begin{bmatrix} \hat{y}_{T+h|T} \\ \hat{y}_{A,T+h|T} \\ \hat{y}_{B,T+h|T} \\ \hat{y}_{AA,T+h|T} \\ \hat{y}_{AB,T+h|T} \\ \hat{y}_{AC,T+h|T} \\ \hat{y}_{BA,T+h|T} \\ \hat{y}_{BB,T+h|T} \end{bmatrix}_{8 \times 1} \quad (4)$$

*exemplo 3: matriz de reconciliação bottom-up*



# MATRIZ DE RECONCILIAÇÃO

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

E se quisermos utilizar toda a informação e não apenas parte do espaço das previsões base?

### O PROBLEMA DE PESQUISA DA RECONCILIAÇÃO ÓTIMA

Estimar uma matriz de reconciliação  $G$  que utilize toda a informação disponível e com o menor erro de previsão





# MATRIZ DE RECONCILIAÇÃO

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

### PROBLEMA DE REGRESSÃO

- Minimização do traço da matriz de covariância dos erros das previsões reconciliadas (MinT<sup>a</sup>)

$$\min_{\tilde{e}} y_{T+h} - \tilde{y}_{T+h} \quad (5)$$

- Mínimos Quadrados Generalizados (MQG)

$$G = (S'W_h^\dagger S)^{-1} S'W_h^\dagger \quad (6)$$

Substituindo  $G$  na Equação 1, temos:

$$\tilde{y} = S(S'W_h^\dagger S)^{-1} S'W_h^\dagger \hat{y}_h \quad (7)$$

---

<sup>a</sup>(WICKRAMASURIYA; ATHANASOPOULOS; HYNDMAN, 2019).



# RECONCILIAÇÃO POR MACHINE LEARNING

## 3 RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

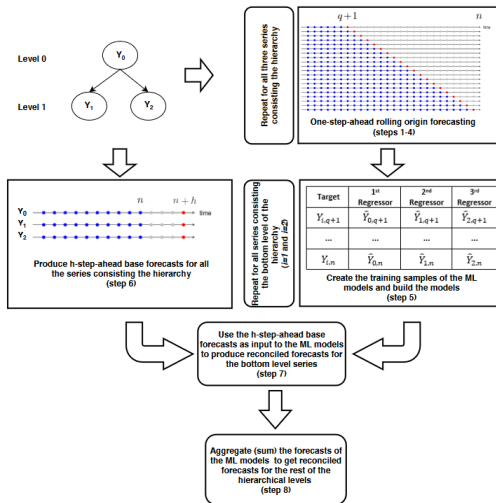


Figure 1: Abordagem de reconciliação ótima por ML. Fonte: Spiliotis et al. (2021)



# SUMÁRIO

## 4 METODOLOGIA

► CONTEXTUALIZAÇÃO DA PESQUISA

► OBJETIVOS

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► **METODOLOGIA**

► REFERÊNCIAS



# DADOS E VARIÁVEIS

## 4 METODOLOGIA

- Estatística Bancária Mensal e por Município (Bacen)
- Municípios (IBGE)
- Saldos de crédito dos verbetes empréstimos e financiamentos
- CNPJ Banestes mas expansível para todo SFN
- 01/2003 - 12/2022
- 37.920 observações (114.480 com nós de agregação)



# DADOS E VARIÁVEIS

## 4 METODOLOGIA

- Estrutura hierárquica
  - total
  - 4 mesorregiões
  - 13 microrregiões
  - 79 agências
- Estrutura agrupada
  - 2 modalidades de crédito



# PREVISÕES BASE

## 4 METODOLOGIA

- Previsões para fora da amostra a serem reconciliadas
- ETS (podem ser obtidas por qualquer método, incluindo ML)
- Treino: 01/2003 - 12/2021
- Horizonte de previsão ( $h$ ): 01/2022 - 12/2022, fora da amostra



# DESIGN DO EXPERIMENTO

## 4 METODOLOGIA

### PERGUNTA MOTIVADORA

*Dada a performance das previsões base, o quanto mais precisas elas se tornam ao aplicar um determinado método de reconciliação?*



# DESIGN DO EXPERIMENTO

## 4 METODOLOGIA

- Métodos de reconciliação:
  - Analíticos: *Bottom-up* e *MinT Shrink*
  - Regressão regularizada: *Elastic Net* (lasso, ridge e CV)
  - Árvores: *Random forest*, *XGBoost* e *LightGBM*
  - *Support Vector Machines* (SVM)
- Estratégias para obtenção da amostra de treino:
  - *Rolling forecast*
  - *Fitted base forecasts*
  - *Reduced fitted base forecasts*





# DESIGN DO EXPERIMENTO

## 4 METODOLOGIA

- Procedimentos para o método *elastic net* (SPILIOTIS et al., 2021)
  1. Obter  $\hat{y}_{t+1}$
  2. Treinar modelo *elastic net* usando (1) como preditores e  $y_{t+1}$  como alvo
  3. Obter  $\hat{y}_{T+h}$
  4. Obter  $\tilde{y}_{T+h}$  passando os preditores (3) ao modelo treinado em (2)
  5. Agregar as previsões reconciliadas para obter as previsões nos demais níveis hierárquicos



# SUMÁRIO

## 5 REFERÊNCIAS

► CONTEXTUALIZAÇÃO DA PESQUISA

► OBJETIVOS

► RECONCILIAÇÃO DE SÉRIES TEMPORAIS HIERÁRQUICAS

► METODOLOGIA

► REFERÊNCIAS



# **BIBLIOGRAFIA**

## **5 REFERÊNCIAS**



# REFERÊNCIAS

## 5 REFERÊNCIAS



BECCALLI, E. et al. Earnings management, forecast guidance and the banking crisis. **The European Journal of Finance**, v. 21, n. 3, p. 242–268, fev. 2015. ISSN 1351-847X. DOI: 10.1080/1351847X.2013.809548. Disponível em: <<https://doi.org/10.1080/1351847X.2013.809548>>. Acesso em: 7 mai. 2023. Citado na p. 3.



GROSS, C. W.; SOHL, J. E. Disaggregation methods to expedite product line forecasting. en. **Journal of Forecasting**, v. 9, n. 3, p. 233–254, 1990. ISSN 1099-131X. DOI: 10.1002/for.3980090304. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/for.3980090304>>. Acesso em: 18 jun. 2023. Citado na p. 18.



HYNDMAN, R.; ATHANASOPOULOS, G. **Forecasting: principles and practice**. 3. ed. Melbourne, Austrália: OTexts, 2021. Disponível em: <<https://otexts.com/fpp3/>>. Citado na p. 5.



# REFERÊNCIAS

## 5 REFERÊNCIAS



SEZER, O. B.; GUDELEK, M. U.; OZBAYOGLU, A. M. **Financial Time Series Forecasting with Deep Learning : A Systematic Literature Review: 2005-2019**. Turquia: arXiv, nov. 2019. arXiv:1911.13288 [cs, q-fin, stat]. Disponível em: <<http://arxiv.org/abs/1911.13288>>. Acesso em: 7 mar. 2023. Citado na p. 3.



SPILIOTIS, E. et al. Hierarchical forecast reconciliation with machine learning. en. **Applied Soft Computing**, v. 112, p. 107756, nov. 2021. ISSN 1568-4946. DOI: 10.1016/j.asoc.2021.107756. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1568494621006773>>. Acesso em: 11 jan. 2023. Citado nas pp. 15, 26, 33.



# REFERÊNCIAS

## 5 REFERÊNCIAS



WICKRAMASURIYA, S. L.; ATHANASOPOULOS, G.; HYNDMAN, R. J. Optimal Forecast Reconciliation for Hierarchical and Grouped Time Series Through Trace Minimization. en. **Journal of the American Statistical Association**, v. 114, n. 526, p. 804–819, abr. 2019. ISSN 0162-1459, 1537-274X. DOI: 10.1080 / 01621459.2018.1448825. Disponível em: <<https://www.tandfonline.com/doi/full/10.1080/01621459.2018.1448825>>. Acesso em: 18 jun. 2023. Citado na p. 25.



# **MÉTODOS DE MACHINE LEARNING PARA RECONCILIAÇÃO ÓTIMA DE SÉRIES TEMPORAIS HIERÁRQUICAS E AGRUPADAS DE INSTITUIÇÕES FINANCEIRAS**

DEFESA DE DISSERTAÇÃO DE MESTRADO

Alberson Miranda, PPGeco/UFES

2024